

# Đăng ký làm Bài tập lớn Machine Learning

Dataset: SUPPORT2 – Study to Understand Prognoses and Preferences for Outcomes and Risks of Treatments

## Thông tin nhóm

| STT | Họ và tên     | MSV      | Phân công   |
|-----|---------------|----------|-------------|
| 1   | Trần Đức Kiên | 23000131 | Trưởng nhóm |
| 2   | Tạ Văn Nghĩa  | 23000145 | Thành viên  |
| 3   | Vũ Tiến Đạt   | 23000111 | Thành viên  |

**Đề tài:** Nhóm bài toán Hồi quy

**Dataset:** SUPPORT2 – UCI Machine Learning Repository (ID: 880)

**Link lấy dữ liệu:** <https://archive.ics.uci.edu/dataset/880/support2>

## 1. Giới thiệu chung

Dataset SUPPORT2 (Study to Understand Prognoses and Preferences for Outcomes and Risks of Treatments) là tập dữ liệu y tế thu thập hồ sơ của 9.105 bệnh nhân bệnh nặng tại 5 bệnh viện lớn ở Hoa Kỳ trong giai đoạn 1989–1994. Nghiên cứu được tài trợ bởi Quỹ Robert Wood Johnson và công bố trên Tạp chí Y học Hoa Kỳ (JAMA) năm 1995.

Mỗi bệnh nhân trong dataset mắc một trong 9 loại bệnh nghiêm trọng, bao gồm: suy hô hấp cấp (ARF), bệnh phổi tắc nghẽn mạn tính (COPD), suy tim sung huyết (CHF), xơ gan, hôn mê, ung thư đại tràng, ung thư phổi, suy đa tạng kèm ác tính và suy đa tạng kèm nhiễm khuẩn huyết. Dữ liệu bao gồm ba nguồn chính: hồ sơ y tế, phỏng vấn bệnh nhân/người đại diện và Chỉ mục Tử vong Quốc gia (NDI).

Mục tiêu ban đầu của nghiên cứu là cải thiện quá trình ra quyết định trong chăm sóc bệnh nhân nặng, nhằm giảm thiểu tình trạng kéo dài sự sống một cách đau đớn và không cần thiết.

### Thông tin tổng quan về dữ liệu:

| Thuộc tính           | Giá trị                                   |
|----------------------|-------------------------------------------|
| Số mẫu               | 9.105                                     |
| Số thuộc tính        | 42                                        |
| Kiểu dữ liệu         | Numeric + Categorical                     |
| Giá trị khuyết thiếu | 33/45 cột có missing values               |
| Nguồn                | UCI Machine Learning Repository (ID: 880) |
| Năm thu thập         | 1989–1994                                 |

## 2. Mô tả dữ liệu

Dữ liệu gồm **42 thuộc tính đầu vào** được chia thành 5 nhóm chính:

- **Nhân khẩu học (5):** `age` (tuổi), `sex` (giới tính), `race` (chủng tộc), `edu` (trình độ học vấn), `income` (thu nhập).
- **Bệnh lý (5):** `dzgroup` (nhóm bệnh chi tiết), `dzclass` (nhóm bệnh tổng quát), `ca` (ung thư), `diabetes` (tiểu đường), `dementia` (sa sút trí tuệ).
- **Chỉ số sinh lý (14):** `meanbp` (huyết áp trung bình), `hrt` (nhịp tim), `resp` (nhịp thở), `temp` (nhiệt độ), `pafi` (tỉ số PaO<sub>2</sub>/FiO<sub>2</sub>), `alb` (albumin), `bili` (bilirubin), `crea` (creatinine), `sod` (natri), `ph`, `glucose`, `bun` (ure máu), `urine` (lượng nước tiểu), `wbhc` (bạch cầu).
- **Mức độ bệnh (4):** `sps` (điểm tiên lượng SUPPORT), `aps` (điểm sinh lý cấp tính), `scoma` (điểm hôn mê), `num.co` (số bệnh đồng thời).
- **Tiên lượng và kết quả (14):** `surv2m`, `surv6m` (xác suất sống ước tính 2 và 6 tháng do mô hình SUPPORT tính), `prg2m`, `prg6m` (tiên lượng của bác sĩ), `dnr` (lệnh không hồi sức), `dnrday` (ngày ký lệnh DNR), `charges` (tổng chi phí điều trị), `totcst` (tổng chi phí thực tế), `totmcst` (chi phí y tế vi tính), `avtisst` (điểm TISS trung bình), `hday` (số ngày nằm viện), `adlp` (chỉ số hoạt động hàng ngày – bệnh nhân tự đánh giá), `adls` (chỉ số hoạt động hàng ngày – người đại diện đánh giá), `adlsc` (chỉ số hoạt động hàng ngày – kết hợp).

## 3. Bài toán Hồi quy

**Biến đầu ra:** `charges` – tổng chi phí bệnh viện (đơn vị: USD), là một đại lượng liên tục với giá trị dao động lớn giữa các bệnh nhân.

**Mục tiêu:** Dự đoán chi phí điều trị của bệnh nhân dựa trên tình trạng sức khỏe, mức độ bệnh và các thông số sinh lý. Bài toán có ý nghĩa thực tiễn cao trong việc lập kế hoạch tài chính bệnh viện và phân bổ nguồn lực y tế.

## 4. Bài toán Phân loại

Từ kết quả bài toán hồi quy, ta chuyển biến đầu ra liên tục `charges` thành biến phân loại bằng cách chia thành **3–4 khoảng** có số lượng mẫu xấp xỉ nhau.

Ví dụ như cách chia 4 nhân dựa trên tứ phân vị:

| Nhãn | Khoảng chi phí | Ý nghĩa                 |
|------|----------------|-------------------------|
| 0    | $< Q_1$        | Chi phí thấp            |
| 1    | $[Q_1, Q_2)$   | Chi phí trung bình thấp |
| 2    | $[Q_2, Q_3)$   | Chi phí trung bình cao  |
| 3    | $\geq Q_3$     | Chi phí cao             |