

Báo cáo Tiền xử lý Dữ liệu SUPPORT2 cho Bài toán Dự đoán Chi phí Điều trị

Trần Đức Kiên

Ngày 19 tháng 4 năm 2026

1 Cấu trúc Dữ liệu và Thống kê Sơ bộ

1.1 Mô tả Cấu trúc Tổng quan

Dữ liệu gốc sau khi được tải về và hợp nhất giữa các tập đặc trưng (features) và mục tiêu (targets) có cấu trúc như sau:

- **Tổng số bản ghi (Rows):** 9,105 dòng, đại diện cho 9,105 bệnh nhân nội trú.
- **Tổng số trường dữ liệu (Columns):** 45 cột, bao gồm các thông tin về nhân khẩu học, chỉ số sinh tồn, chẩn đoán bệnh lý và chi phí điều trị.
- **Phân loại biến số:** Dữ liệu bao gồm cả biến Numeric và Category

1.2 Thống kê Sơ bộ và Đặc điểm Dữ liệu

Qua bước khảo sát ban đầu, chúng tôi ghi nhận một số đặc điểm thống kê quan trọng của tập dữ liệu:

Đặc trưng tiêu biểu	Giá trị trung bình	Độ lệch (Skew)	Tỷ lệ thiếu (%)
Tuổi (age)	62.7 năm	-0.58	0%
Huyết áp (meanbp)	84.6 mmHg	1.25	0.01%
Albumin (alb)	3.12 g/dL	-0.16	38.8%
Bilirubin (bili)	2.27 mg/dL	4.34	48.1%
Chi phí (charges)	\$59,715	4.68	1.9%

Bảng 1: Thống kê sơ bộ một số biến số học quan trọng

Nhận xét từ thống kê sơ bộ:

1. **Vấn đề dữ liệu khuyết:** Các biến sinh hóa như alb, bili, pafi có tỷ lệ thiếu rất cao (trên 30%).
2. **Độ lệch phân phối:** Biến mục tiêu charges và các biến như bili, crea có độ lệch phải (Positive Skew) cực lớn, báo hiệu cần phải áp dụng biến đổi Logarit để đưa về phân phối chuẩn.
3. **Biến phân loại:** Các biến như nhóm bệnh (dzgroup) và chủng tộc (race) có sự phân bố không đồng đều.

2 Làm sạch Dữ liệu

2.1 Xử lý Biến mục tiêu và Hiện tượng Rò rỉ Dữ liệu

Để đảm bảo mô hình có thể ứng dụng trong thực tế ngay khi bệnh nhân vừa nhập viện, chúng tôi áp dụng các quy tắc nghiêm ngặt:

- **Loại bỏ bản ghi khuyết Target:** Xóa bỏ 172 bản ghi không chứa dữ liệu ở biến mục tiêu `charges`.
- **Triệt tiêu rò rỉ dữ liệu (Data Leakage):** Xóa bỏ toàn bộ các biến chứa thông tin của "tương lai", tức là những kết quả chỉ biết sau khi quá trình điều trị kết thúc. Các biến bị loại bỏ bao gồm trạng thái sinh tử (`death`, `hospdead`), tiên lượng thời gian (`surv2m`, `surv6m`), và các biến chi phí khác có tính tương quan nội sinh (`totcst`, `totmcst`).

2.2 Kiểm định Y khoa và Giá trị Khuyết

Thay vì xóa bỏ các hàng có dữ liệu thiếu làm mất mát thông tin, hệ thống áp dụng chiến lược điền khuyết (Imputation) đa tầng:

1. **Ngưỡng sinh lý (Out-of-range):** Đối chiếu các chỉ số như nhịp tim, huyết áp với giới hạn sinh tồn của con người để loại bỏ các lỗi nhập liệu.
2. **Tri thức chuyên gia (Domain Knowledge):** Sử dụng các giá trị mặc định được khuyến nghị bởi tác giả bộ dữ liệu (Giáo sư Frank Harrell) cho các chỉ số sinh hóa cốt lõi (ví dụ: Albumin = 3.5, Creatinine = 1.01).
3. **Xử lý thống kê:** Với các biến số học lệch chuẩn (skewed), sử dụng **Median** (Trung vị) để giảm thiểu tác động của ngoại lai (Outliers). Các biến phân loại được điền bằng **Mode**.

3 Encoding

Thuật toán Học máy bản chất là các phép toán ma trận, do đó không thể trực tiếp xử lý các biến văn bản (Categorical). Tùy thuộc vào bản chất của từng biến, chúng tôi áp dụng ba cơ chế mã hóa khác nhau:

- **Binary Encoding:** Áp dụng cho các biến phân loại chỉ có 2 trạng thái. Cụ thể, biến giới tính (`sex`) được ánh xạ trực tiếp thành các số nguyên: `male` → 0 và `female` → 1.
- **Ordinal Encoding:** Áp dụng cho các hạng mục mang ý nghĩa về mặt thứ bậc hoặc mức độ tăng dần. Các giá trị được chuyển đổi thành các số nguyên bảo toàn khoảng cách thứ bậc nội tại:
 - **Thu nhập (income):** Chuyển đổi theo mức độ tăng dần của tài chính: `under $11k` → 0; `$11-$25k` → 1; `$25-$50k` → 2; và `>$50k` → 3.
 - **Tình trạng ung thư (ca):** Phản ánh mức độ trầm trọng của bệnh lý: `no` (Không mắc) → 0; `yes` (Có mắc nhưng chưa di căn) → 1; và `metastatic` (Đã di căn) → 2.

- **One-Hot Encoding:** Được sử dụng cho các biến danh nghĩa (Nominal) không có tính thứ tự như chủng tộc (`race`), nhóm bệnh (`dzgroup`), lớp bệnh (`dzclass`), và lệnh không hồi sức (`dnr`).

Ví dụ: Biến chủng tộc (`race`) có 5 lớp giá trị. Thuật toán OHE chỉ sinh ra 4 cột mới (như `race_black`, `race_hispanic`, v.v.). Nếu một bệnh nhân có giá trị 0 ở cả 4 cột này, hệ thống ma trận sẽ ngầm định tự hiểu bệnh nhân đó thuộc nhóm thứ 5 đã bị làm ẩn (ví dụ: `race_white`).

4 Chuẩn hóa

4.1 Log Transformation

Chi phí y tế (`charges`) và một số biến lâm sàng có phân phối cực kỳ lệch phải (Right-skewed). Để đưa phân phối về dạng tiệm cận chuẩn (Normal Distribution), hàm Logarit tự nhiên được áp dụng:

$$x_{new} = \ln(x + 1) \quad (1)$$

Hằng số +1 được cộng thêm (Log1p) nhằm ngăn chặn lỗi toán học không xác định khi $x = 0$. Quá trình này đã kéo độ lệch (skewness) của biến `charges` từ 4.687 về mức hoàn hảo 0.00.

4.2 Z-score Normalization

Để các đặc trưng có dải đo lường khác nhau (như Tuổi tác và Nồng độ máu) có sức ảnh hưởng ngang bằng nhau khi đưa vào hàm suy hao của thuật toán, 25 biến số học liên tục thuộc tập đặc trưng (Features) đã được tiêu chuẩn hóa theo công thức:

$$Z = \frac{x - \mu}{\sigma} \quad (2)$$

Trong đó μ là giá trị trung bình và σ là độ lệch chuẩn. Sau biến đổi, các biến có trung bình xấp xỉ 0 và độ lệch chuẩn bằng 1. Các thông số biến đổi được lưu trữ vào tệp JSON phục vụ cho pha kiểm thử (Inference).

5 Kết luận

Tóm tắt kết quả cấu trúc dữ liệu cuối cùng được trình bày trong Bảng 2.

Đặc điểm cấu trúc	Kết quả
Số lượng bản ghi gốc	9,105
Số lượng bản ghi khả dụng	8,933
Kích thước không gian đặc trưng	47 cột (đã qua OHE)
Biến mục tiêu (Target)	<code>charges</code> (dạng Log1p)
Tỷ lệ dữ liệu khuyết (Missing Rate)	0%

Bảng 2: Tóm lược cấu trúc tập dữ liệu sau quá trình tiền xử lý